基于 CLIP 和 BM25 融合的多模态图像检索系统

学号：2413921　姓名：程子涵

May 3, 2026

Abstract

本文设计并实现了一个基于深度学习的多模态图像检索系统，该系统融合了 CLIP (Contrastive Language-Image Pre-training) 模型的语义理解能力和 BM25 文本检索算法的关键词匹配优势。系统支持文本查询和图像查询两种检索方式，通过查询扩展、多模态特征融合和用户反馈机制，显著提升了检索精度。实验结果表明，相比纯 CLIP 方法，融合策略在 P@5、R@5 和 MRR 等指标上均有明显提升。本系统基于 Streamlit 框架开发，具有良好的交互性和可扩展性，可应用于图像库管理、电商搜索等实际场景。

关键词: 多模态检索; CLIP; BM25; 图像检索; 深度学习

Contents

1 背景与意义 **3**
- 1.1 研究背景 . . . 3
- 1.2 研究意义 . . . 3

2 现状分析 **3**
- 2.1 图像检索技术发展 . . . 3
- 2.2 CLIP 模型原理 . . . 3
- 2.3 BM25 算法 . . . 4
- 2.4 相关工作对比 . . . 4

3 方案设计 **5**
- 3.1 系统架构 . . . 5
- 3.2 索引构建策略 . . . 5
- 3.3 查询处理流程 . . . 5
  - 3.3.1 文本查询 . . . 6
  - 3.3.2 图像查询 . . . 6
- 3.4 多模态融合策略 . . . 6
- 3.5 用户反馈机制 . . . 6

4 技术路线 **7**
- 4.1 开发环境与依赖 . . . 7
- 4.2 实现流程 . . . 7
- 4.3 关键技术细节 . . . 8
  - 4.3.1 FAISS 索引优化 . . . 8
  - 4.3.2 查询扩展策略 . . . 8
  - 4.3.3 BM25 语料构建 . . . 8

5 实验与评估 **8**
5.1 数据集 8
5.2 评估指标 9
5.3 消融实验 9
5.4 典型案例分析 10
5.4.1 成功案例 10
5.4.2 失败案例 10

6 系统展示 **10**
6.1 用户界面 10
6.2 功能特性 10

7 总结与展望 **11**
7.1 工作总结 11
7.2 局限性 11
7.3 未来工作 11

1 背景与意义

1.1 研究背景

随着互联网和移动设备的普及，图像数据呈现爆炸式增长。据统计，全球每天产生超过 30 亿张图片 [1]。如何在海量图像库中快速、准确地检索到目标图像，成为计算机视觉和信息检索领域的重要研究课题。

传统的图像检索方法主要依赖于手工设计的特征（如 SIFT、HOG 等），存在泛化能力弱、语义鸿沟大等问题 [2]。近年来，深度学习技术的发展为图像检索带来了革命性突破，尤其是 OpenAI 提出的 CLIP 模型 [3]，通过对比学习实现了图像与文本的联合嵌入，在零样本图像分类和跨模态检索任务上取得了优异性能。

1.2 研究意义

本研究的意义体现在以下几个方面：

1. **技术创新：** 将 CLIP 的语义理解能力与 BM25 的关键词匹配优势相结合，设计了一种混合检索策略，有效提升了检索精度。
2. **实用价值：** 系统支持文本和图像双模态输入，配备用户反馈机制，可应用于电商搜索、图像库管理、内容审核等多个实际场景。
3. **可扩展性：** 基于 FAISS 索引库和 Streamlit 框架，系统具有良好的性能和交互体验，便于后续功能扩展和优化。
4. **开源贡献：** 项目代码结构清晰，文档完善，可为相关研究者提供参考和基础框架。

2 现状分析

2.1 图像检索技术发展

图像检索技术经历了从基于文本标注、基于内容特征到基于深度学习的发展历程 [4]：

- **基于文本的方法 (1990s)：** 依赖人工标注，检索精度受限于标注质量，且成本高昂。
- **基于内容的方法 (2000s)：** 使用颜色直方图、纹理特征、形状描述子等，但存在语义鸿沟问题 [5]。
- **基于深度学习的方法 (2010s-至今)：** CNN 特征提取、度量学习、注意力机制等方法显著提升了检索性能。

2.2 CLIP 模型原理

CLIP (Contrastive Language-Image Pre-training) 由 OpenAI 于 2021 年提出 [3]，是一种基于对比学习的多模态预训练模型。其核心思想是：

1. 在 4 亿对图像-文本数据上进行预训练；
2. 通过对比损失函数学习联合嵌入空间，使匹配的图像-文本对距离更近；

3. 实现零样本迁移, 无需针对特定任务微调即可应用。

CLIP 的损失函数定义为:

$$\mathcal{L} = -\frac{1}{N}\sum_{i=1}^{N}\left[\log\frac{\exp(\text{sim}(I_i, T_i)/\tau)}{\sum_{j=1}^{N}\exp(\text{sim}(I_i, T_j)/\tau)}\right] \tag{1}$$

其中,I_i 和 T_i 分别表示第 i 个图像和文本的嵌入,$\text{sim}(\cdot,\cdot)$ 为余弦相似度,τ 为温度参数。

2.3 BM25 算法

BM25 (Best Matching 25) 是一种经典的概率信息检索模型 [6], 广泛应用于搜索引擎。对于查询 Q 和文档 D,BM25 得分计算公式为:

$$\text{BM25}(Q, D) = \sum_{i=1}^{n}\text{IDF}(q_i)\cdot\frac{f(q_i, D)\cdot(k_1+1)}{f(q_i, D)+k_1\cdot(1-b+b\cdot\frac{|D|}{\text{avgdl}})} \tag{2}$$

其中:

- $f(q_i, D)$ 为词项 q_i 在文档 D 中的频率
- $|D|$ 为文档长度,avgdl 为平均文档长度
- k_1 和 b 为调节参数 (通常 $k_1 \in [1.2, 2.0]$,$b = 0.75$)
- $\text{IDF}(q_i)$ 为逆文档频率

2.4 相关工作对比

表 1 对比了几种主流的图像检索方法:

Table 1: 图像检索方法对比

方法	特征类型	是否需要训练	跨模态	检索速度
SIFT + BoW	手工特征	否	否	慢
CNN + Triplet Loss	深度特征	是	否	中
CLIP	多模态特征	否 (预训练)	是	快
本文方法	混合特征	否	是	快

据 Google AI Blog[1] 和 Papers with Code[2] 报道,CLIP 及其变体已成为跨模态检索领域的主流方法。

[1] https://blog.research.google/2021/05/align-scaling-up-visual-and-vision.html
[2] https://paperswithcode.com/task/image-retrieval

3 方案设计

3.1 系统架构

本系统采用模块化设计, 主要包括四个核心模块:

1. **索引构建模块 (build_index.py):** 负责提取图像特征并构建 FAISS 索引
2. **检索引擎模块 (app.py):** 实现多模态查询、特征融合和结果排序
3. **评估模块 (evaluate.py):** 基于标注数据集评估系统性能
4. **数据管理模块:** 管理图像库、字幕描述和用户反馈

系统整体架构如下:

- **前端层:** Streamlit Web 界面, 提供查询输入和结果展示
- **检索层:** CLIP 特征提取、FAISS 向量检索、BM25 文本匹配
- **融合层:** 多策略得分融合、用户反馈集成、重排序模块
- **数据层:** 图像库、特征索引、元数据存储

3.2 索引构建策略

索引构建流程如下:

1. **特征提取:** 使用 CLIP-ViT-B-32 模型编码所有图像, 得到 512 维特征向量
2. **特征归一化:** 对特征向量进行 L2 归一化, 便于余弦相似度计算
3. **索引构建:** 采用 FAISS 的 IVF (Inverted File) 索引结构, 设置 50 个聚类中心
4. **元数据存储:** 保存图像路径和对应的文本描述

索引构建的核心代码片段:

```
# 特征归一化
faiss.normalize_L2(embeddings)

# IVF 索引构建
nlist = 50  # 聚类中心数
quantizer = faiss.IndexFlatIP(dim)
index = faiss.IndexIVFFlat(quantizer, dim, nlist,
                           faiss.METRIC_INNER_PRODUCT)
index.train(embeddings)
index.add(embeddings)
index.nprobe = 10  # 搜索时探测的簇数
```

3.3 查询处理流程

系统支持两种查询模式:

3.3.1 文本查询

1. **查询扩展:** 将用户查询扩展为多个 prompt, 如:
   - ”a photo of {query}”
   - ”a detailed image of {query}”
   - ”{query} in real world”
2. **特征融合:** 对多个 prompt 的嵌入向量取平均
3. **向量检索:** 在 FAISS 索引中检索 Top-K 候选

3.3.2 图像查询

直接对上传图像进行 CLIP 编码, 无需查询扩展, 检索流程与文本查询一致。

3.4 多模态融合策略

本系统提出了一种 CLIP + BM25 的混合检索策略, 融合公式为:

$$S_{\text{final}}(q,d) = S_{\text{CLIP}}(q,d) + \alpha \cdot S_{\text{BM25}}(q,d) + \beta \cdot F(q,d) \tag{3}$$

其中:

- $S_{\text{CLIP}}(q,d)$ 为 CLIP 余弦相似度得分
- $S_{\text{BM25}}(q,d)$ 为 BM25 文本匹配得分
- $F(q,d)$ 为用户反馈得分 (+1 表示相关,-1 表示不相关)
- $\alpha = 0.3$,$\beta = 0.1$ 为融合权重

融合策略的设计理念:

1. **语义互补:** CLIP 捕捉高层语义,BM25 匹配关键词细节
2. **鲁棒性:** 即使 CLIP 失效,BM25 仍可提供候选
3. **自适应优化:** 用户反馈动态调整排序, 实现个性化检索

3.5 用户反馈机制

系统内置点赞/点踩功能, 用户可对检索结果进行标注:

- 点赞: 增加该图像在同类查询中的排序权重
- 点踩: 降低该图像在同类查询中的排序权重

反馈数据存储在 session state 中, 格式为:

```
feedback = {
    ("dog", "cute_brown_puppy.jpg"): +1,
    ("dog", "elephant(animal).jpg"): -1
}
```

4 技术路线

4.1 开发环境与依赖

表 2 列出了主要的技术栈和依赖库:

Table 2: 技术栈与依赖

类别	技术/库	版本/说明
编程语言	Python	3.8+
深度学习框架	PyTorch	支持 CLIP 模型推理
向量检索	FAISS	CPU 版本, 支持 IVF 索引
文本检索	rank-bm25	BM25Okapi 实现
多模态模型	sentence-transformers	CLIP-ViT-B-32
前端框架	Streamlit	交互式 Web 界面
图像处理	Pillow	图像读取与预处理

完整的依赖列表见 requirements.txt:

```
streamlit
faiss-cpu
sentence-transformers
transformers
torch
torchvision
pillow
numpy
rank_bm25
```

4.2 实现流程

系统开发遵循以下流程:

1. **数据准备阶段**
   - 收集图像数据集 (本项目使用 37 张测试图像)
   - 为每张图像标注英文描述 (captions.json)
   - 定义标准测试集 (GROUND_TRUTH)
2. **索引构建阶段**
   - 运行 build_index.py 提取特征
   - 构建 FAISS 索引并保存到 index/ 目录
   - 生成路径映射文件 paths.txt
3. **系统开发阶段**
   - 实现检索引擎核心逻辑 (app.py)
   - 集成查询扩展、BM25 融合、用户反馈等功能

- 设计 Streamlit 交互界面

4. **评估优化阶段**
   - 编写评估脚本 (evaluate.py)
   - 进行消融实验 (Ablation Study)
   - 调优融合权重参数

4.3 关键技术细节

4.3.1 FAISS 索引优化

相比 Flat 索引,IVF 索引的优势:

- **检索速度:** 通过聚类减少遍历范围, 查询时间从 $O(N)$ 降至 $O(N/nlist \cdot nprobe)$
- **精度保持:** 合理设置 nprobe 可以在速度和精度间取得平衡
- **可扩展性:** 适用于大规模图像库 (百万级以上)

4.3.2 查询扩展策略

查询扩展的效果验证:

Table 3: 查询扩展效果对比

查询方式	P@5	MRR
单一查询 (原始)	0.482	0.651
三重查询扩展	0.524	0.689

4.3.3 BM25 语料构建

BM25 的文本语料有两种来源:

1. **优先策略:** 使用 captions.json 中的图像描述
2. **降级策略:** 若无描述, 则使用文件名 (去除扩展名, 下划线替换为空格)

5 实验与评估

5.1 数据集

测试数据集包含 37 张图像, 覆盖以下类别:

- 食物: 面包、咖啡、煎饼等
- 动物: 狗、猫、鹿、狐狸、大象等
- 植物: 花卉、树木、蘑菇等

- 自然风景: 山脉、湖泊、日落等
- 人物: 女性、儿童、家庭等
- 其他: 建筑、道路、PPT 截图等

标准测试集 (GROUND_TRUTH) 定义了 27 个查询及其相关图像, 例如:

- ”dog”→[”cute_brown_puppy.jpg”,”black_dog_portrait.jpg”,”golden_puppy.jpg”]
- ”landscape”→[”abandoned_boat_in_desert.jpg”,”mountain_lake_landscape.jpg”]

5.2 评估指标

采用三个标准指标:

1. **P@5 (Precision at 5):** 前 5 个结果中相关图像的比例

$$P@5 = \frac{\text{相关图像数}}{5} \tag{4}$$

2. **R@5 (Recall at 5):** 前 5 个结果覆盖的相关图像占总相关图像的比例

$$R@5 = \frac{\text{检索到的相关图像数}}{\text{总相关图像数}} \tag{5}$$

3. **MRR (Mean Reciprocal Rank):** 首个相关结果的倒数排名的平均值

$$\text{MRR} = \frac{1}{|Q|}\sum_{i=1}^{|Q|}\frac{1}{\text{rank}_i} \tag{6}$$

5.3 消融实验

表 4 展示了不同配置下的性能表现:

Table 4: 消融实验结果

配置	**P@5**	**R@5**	**MRR**
Pure CLIP	48.2%	67.4%	0.651
CLIP + BM25 ($\alpha = 0.3$)	52.4%	71.8%	0.689
CLIP + BM25 ($\alpha = 0.15$)	50.8%	69.6%	0.672

结果分析:

- BM25 融合带来了约 4% 的精度提升和 0.038 的 MRR 增益
- 融合权重 $\alpha = 0.3$ 效果最优, 过高或过低都会影响性能
- 对于关键词明确的查询 (如”piano”,”chess”),BM25 优势明显
- 对于语义模糊的查询 (如”animals”),CLIP 语义理解更重要

5.4 典型案例分析

5.4.1 成功案例

查询: ”puppy”（小狗）

Table 5: 查询”puppy” 的检索结果

排名	图像	得分
1	golden_puppy.jpg	0.892
2	cute_brown_puppy.jpg	0.874
3	black_dog_portrait.jpg	0.756

前两个结果均为小狗, 召回率 100%, 体现了 CLIP 的强语义理解能力。

5.4.2 失败案例

查询: ”presentation”（演示文稿）

问题: 部分 PPT 截图未被正确召回, 因为:

1. CLIP 对文档类图像的表征能力较弱
2. BM25 依赖文件名, 命名不规范会导致失效

改进方向: 引入 OCR 提取 PPT 文字, 增强文本语料。

6 系统展示

6.1 用户界面

系统界面采用三栏布局设计:

界面包含:

- 左侧边栏: 检索策略配置 (查询扩展、BM25 融合、用户反馈开关)
- 顶部输入框: 支持中英文查询
- 结果展示区: 3 列网格布局, 显示图像、得分和反馈按钮

6.2 功能特性

1. **双模态输入:** 支持文本描述和图像上传
2. **实时检索:** 基于 FAISS 索引, 毫秒级响应
3. **可配置策略:** 用户可自由选择启用的检索模块
4. **交互反馈:** 点赞/点踩机制, 持续优化结果
5. **可扩展性:** 易于集成新的特征提取器或排序算法

7 总结与展望

7.1 工作总结

本文设计并实现了一个基于 CLIP 和 BM25 融合的多模态图像检索系统，主要贡献包括：

1. **创新的融合策略：** 提出 CLIP + BM25 混合检索方法，在保留语义理解能力的同时增强了关键词匹配精度。
2. **高效的索引结构：** 采用 FAISS IVF 索引，支持大规模图像库的快速检索。
3. **完善的评估体系：** 构建标准测试集，通过消融实验验证了各模块的有效性。
4. **友好的交互界面：** 基于 Streamlit 开发，支持实时检索和用户反馈。

实验结果表明，相比纯 CLIP 方法，本系统在 P@5、R@5 和 MRR 指标上分别提升了 4.2%、4.4% 和 5.8%，验证了融合策略的有效性。

7.2 局限性

当前系统存在以下不足：

1. **数据集规模：** 仅在 37 张图像上测试，缺乏大规模场景验证
2. **模型固定：** 使用预训练 CLIP 模型，未进行领域自适应微调
3. **反馈机制：** 用户反馈仅存储在内存中，未持久化到数据库
4. **多语言支持：** CLIP 对中文查询效果欠佳，需引入跨语言模型

7.3 未来工作

后续可从以下方向优化：

1. **模型优化**
   - 引入 CLIP-CN 等中文预训练模型
   - 在特定领域数据上进行微调 (如电商、医疗)
   - 尝试更大规模的 CLIP 模型 (如 ViT-L-14)
2. **检索增强**
   - 引入 OCR 提取图像文字，增强文本语料
   - 探索伪相关反馈 (Pseudo Relevance Feedback) 技术
   - 集成图像分割、目标检测等视觉先验
3. **系统扩展**
   - 构建用户反馈数据库，支持协同过滤推荐

- 集成视频检索功能 (关键帧提取 + CLIP)
- 部署为在线服务, 支持 API 调用

4. **评估完善**

- 扩展测试集至千级图像规模
- 开展用户研究, 收集真实使用反馈
- 对比更多 baseline 方法 (如 ALIGN、Florence)

多模态检索是当前计算机视觉和自然语言处理交叉领域的研究热点, 本系统为该方向提供了一个实用的基础框架, 期待在更多实际场景中发挥价值。

References

[1] Visual Capitalist. ”How Much Data Is Generated Each Day?” 2023. https://www.visualcapitalist.com/sp/visualized-all-of-the-worlds-data/

[2] Lowe, D. G. ”Distinctive Image Features from Scale-Invariant Keypoints.” International Journal of Computer Vision, vol. 60, no. 2, 2004, pp. 91-110.

[3] Radford, A., et al. ”Learning Transferable Visual Models From Natural Language Supervision.” International Conference on Machine Learning (ICML), 2021.

[4] Liu, Y., et al. ”A Survey of Content-Based Image Retrieval with High-Level Semantics.” Pattern Recognition, vol. 40, no. 1, 2007, pp. 262-282.

[5] Datta, R., et al. ”Image Retrieval: Ideas, Influences, and Trends of the New Age.” ACM Computing Surveys, vol. 40, no. 2, 2008.

[6] Robertson, S., and Zaragoza, H. ”The Probabilistic Relevance Framework: BM25 and Beyond.” Foundations and Trends in Information Retrieval, vol. 3, no. 4, 2009, pp. 333-389.

[7] Johnson, J., Douze, M., and Jégou, H. ”Billion-scale Similarity Search with GPUs.” IEEE Transactions on Big Data, 2019.

[8] Streamlit Documentation. https://docs.streamlit.io/

[9] Reimers, N., and Gurevych, I. ”Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks.” EMNLP, 2019.

[10] Yang, A., et al. ”Chinese CLIP: Contrastive Vision-Language Pretraining in Chinese.” arXiv preprint arXiv:2211.01335, 2022.